



UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO
FACULTAD DE INGENIERÍA



Inteligencia Artificial
SEMESTRE 2026 - 2

Modelos y aplicaciones de la IA

NO. Equipo	07
PROFESOR	<i>Miguel Pérez Gaspar</i>
INTEGRANTES	<i>321193692</i> <i>424065465</i> <i>424104230</i> <i>424063980</i> <i>424099149</i>
GRUPO	06
FECHA DE ENTREGA	<i>25 de mayo de 2026</i>

Índice

1. Introducción	4
2. Concepto de modelo en Inteligencia Artificial	4
2.1. ¿Qué es un modelo de IA?	4
2.2. Elementos generales de un modelo	5
2.3. Diferencia entre modelo, algoritmo, sistema y agente	5
2.4. Importancia de elegir un modelo adecuado	5
3. Los Modelos de Inteligencia Artificial	6
3.1. Modelos basados en reglas e IA simbólica	6
3.1.1. Definición	6
3.1.2. Funcionamiento general	6
3.1.3. Ejemplo aplicado	6
3.1.4. Análisis	6
3.2. Modelos probabilísticos	7
3.2.1. Definición	7
3.2.2. Funcionamiento general	7
3.2.3. Ejemplo aplicado	7
3.2.4. Análisis	7
3.3. Modelos bioinspirados	8
3.3.1. Definición	8
3.3.2. Redes neuronales artificiales	8
3.3.3. Aprendizaje profundo	8
3.3.4. Ejemplo aplicado	8
3.3.5. Análisis	8
3.4. Modelos de toma de decisiones	9
3.4.1. Definición	9
3.4.2. Elementos principales	9
3.4.3. Modelos de búsqueda	9
3.4.4. Aprendizaje por refuerzo como modelo de decisión	9
3.4.5. Ejemplo aplicado	9
3.4.6. Análisis	10

4. Comparación entre los modelos de IA	10
5. Agentes inteligentes y su relación con los modelos	11
5.1. ¿Qué es un agente inteligente?	11
5.2. Diferencia entre modelo y agente	11
5.3. Agentes de reflejo simple	11
5.3.1. Ejemplo aplicado	11
5.3.2. Análisis	11
5.4. Agentes basados en metas	11
5.4.1. Ejemplo aplicado	12
5.4.2. Análisis	12
5.5. Agentes basados en utilidad y aprendizaje	12
6. Representación de problemas y búsqueda de soluciones	12
6.1. ¿Qué significa representar un problema en IA?	12
6.2. Elementos de la representación de problemas	12
6.3. Ejemplo aplicado: el mensajero perdido	13
6.4. Métodos de búsqueda	13
6.5. Relación entre problema, modelo y agente	13
7. Aplicaciones integradoras de la Inteligencia Artificial	13
7.1. Visión por computadora	13
7.1.1. Ejemplo aplicado	13
7.1.2. Análisis	14
7.2. Procesamiento del Lenguaje Natural	14
7.2.1. Ejemplo aplicado	14
7.2.2. Análisis	14
7.3. Robótica, autonomía y sistemas integrados	14
8. Discusión final: selección del enfoque adecuado	15
8.1. No existe un modelo universal	15
8.2. Criterios para seleccionar un modelo o agente	15
8.3. Importancia de los sistemas híbridos	15
9. Conclusión	16
10. Bibliografía	17

1. Introducción

La Inteligencia Artificial (IA) es una rama de las ciencias computacionales orientada al desarrollo de sistemas capaces de percibir, razonar, aprender, tomar decisiones y actuar en un entorno. A diferencia de un programa tradicional, un sistema de IA no solo ejecuta instrucciones fijas, sino que puede adaptarse a datos, objetivos, restricciones e incertidumbre.

El propósito de este trabajo es analizar los principales modelos de IA abordados durante el curso: modelos basados en reglas, probabilísticos, bioinspirados y de toma de decisiones. Para cada modelo se explica su concepto, funcionamiento general, ejemplo de aplicación, ventajas y limitaciones.

Como base teórica se retoma el enfoque de Russell y Norvig, quienes estudian la IA desde la perspectiva de los agentes racionales [1]. A partir de este marco, el ensayo distingue entre modelos y agentes: un modelo representa, aprende o decide sobre un aspecto del problema, mientras que un agente utiliza uno o varios modelos para actuar dentro de un ambiente.

2. Concepto de modelo en Inteligencia Artificial

2.1. ¿Qué es un modelo de IA?

Un modelo de Inteligencia Artificial es una representación formal de un problema, fenómeno o proceso. Su función es organizar información para que un sistema pueda inferir, reconocer patrones, estimar probabilidades, generar predicciones o seleccionar acciones.

Estos modelos pueden representarse mediante reglas explícitas, distribuciones probabilísticas, redes neuronales o estructuras de estados, acciones y costos. Por ello, un modelo no debe entenderse solo como un algoritmo, sino como una forma de representar conocimiento, datos o relaciones relevantes de un dominio.

2.2. Elementos generales de un modelo

Aunque los modelos de IA pueden variar considerablemente, la mayoría incluye algunos elementos comunes:

- **Entradas:** información que recibe el modelo, como datos, percepciones, ejemplos o estados del ambiente.
- **Representación interna:** estructura que organiza el conocimiento, como reglas, parámetros, probabilidades, estados, pesos o relaciones.
- **Proceso de inferencia o aprendizaje:** mecanismo mediante el cual el modelo produce una conclusión, predicción, clasificación o decisión.
- **Salida:** resultado generado por el modelo, como una etiqueta, una acción recomendada, una predicción o una estimación.
- **Medida de desempeño:** criterio para evaluar si el modelo funciona adecuadamente.
- **Limitaciones:** condiciones bajo las cuales el modelo puede fallar o perder precisión.

2.3. Diferencia entre modelo, algoritmo, sistema y agente

Para evitar confusiones, es importante distinguir entre modelo, algoritmo, sistema y agente. El **modelo** representa o aprende una parte del problema. El **algoritmo** es el procedimiento que permite entrenar, buscar, calcular o actualizar el modelo. El **sistema de IA** integra modelos, datos, interfaces, sensores, actuadores o procesos completos. El **agente**, por su parte, es una entidad que percibe un ambiente, toma decisiones y actúa sobre él.

Así, un modelo puede formar parte de un agente, pero no todo modelo es un agente. Por ejemplo, una red neuronal que clasifica imágenes es un modelo; un robot que usa esa red neuronal para identificar objetos, planear una ruta y moverse dentro de un espacio físico es un agente que integra varios modelos.

2.4. Importancia de elegir un modelo adecuado

Seleccionar un modelo de IA no consiste solamente en elegir la técnica más avanzada. La elección depende del tipo de problema, los datos disponibles, la incertidumbre del ambiente, la necesidad de explicación, los recursos computacionales y los riesgos asociados. Algunos problemas requieren reglas claras; otros requieren manejar incertidumbre; otros necesitan aprender patrones a partir de datos; y otros exigen planear acciones en secuencia.

3. Los Modelos de Inteligencia Artificial

3.1. Modelos basados en reglas e IA simbólica

3.1.1. Definición

Los modelos basados en reglas representan el conocimiento mediante símbolos, relaciones lógicas y reglas explícitas del tipo condición–acción. Forman parte de la IA simbólica, cuyo objetivo es modelar el razonamiento de manera comprensible para los humanos [2].

3.1.2. Funcionamiento general

El conocimiento se almacena en una base de reglas o base de conocimiento. Un motor de inferencia analiza los hechos disponibles, aplica las reglas correspondientes y genera una conclusión. Los sistemas expertos son una de sus aplicaciones más representativas.

3.1.3. Ejemplo aplicado

Un sistema experto médico puede usar reglas para relacionar síntomas, antecedentes y resultados de laboratorio con posibles diagnósticos. Aunque hoy muchos sistemas integran aprendizaje automático, las reglas siguen siendo útiles cuando se requiere explicación y trazabilidad.

3.1.4. Análisis

Su principal ventaja es la interpretabilidad, ya que sus conclusiones pueden justificarse mediante reglas explícitas. Por ello se aplican en medicina, industria, finanzas y derecho. Su limitación principal es la rigidez: si el dominio cambia o hay muchas excepciones, la base de conocimiento debe actualizarse constantemente.

3.2. Modelos probabilísticos

3.2.1. Definición

Los modelos probabilísticos permiten razonar cuando la información es incompleta, incierta o variable. En lugar de afirmar que una hipótesis es totalmente verdadera o falsa, asignan probabilidades y actualizan sus creencias cuando reciben nueva evidencia. Este enfoque es fundamental en ambientes estocásticos, donde el resultado de una acción no puede predecirse con total seguridad.

3.2.2. Funcionamiento general

Estos modelos trabajan con hipótesis, evidencia y relaciones de probabilidad. Cuando aparece nueva información, el modelo actualiza la probabilidad de cada hipótesis. Los modelos bayesianos son representativos de este enfoque, ya que permiten modificar una creencia inicial a partir de evidencia observada. Russell y Norvig consideran el razonamiento probabilístico una parte esencial de la IA cuando los agentes deben decidir bajo incertidumbre [1].

3.2.3. Ejemplo aplicado

En diagnóstico médico, un síntoma no garantiza una enfermedad específica. La fiebre puede estar relacionada con múltiples causas. Un modelo probabilístico combina síntomas, antecedentes y estudios clínicos para estimar qué hipótesis es más probable. Otro ejemplo es un filtro de spam, que calcula la probabilidad de que un correo sea no deseado a partir de palabras, remitentes y patrones previos.

3.2.4. Análisis

Su ventaja principal es que permiten tomar decisiones razonables con información incompleta. Se aplican en diagnóstico médico, sensores inciertos, reconocimiento de voz, filtros de spam, predicción de riesgos y sistemas de recomendación. Su limitación es que dependen de probabilidades confiables y de supuestos adecuados. Si el modelo ignora variables importantes o las probabilidades están mal estimadas, las conclusiones pueden ser incorrectas.

3.3. Modelos bioinspirados

3.3.1. Definición

Los modelos bioinspirados toman como referencia procesos biológicos. En IA, el ejemplo más representativo son las redes neuronales artificiales, inspiradas de forma abstracta en el sistema nervioso. Estos modelos aprenden a partir de datos mediante unidades conectadas y pesos ajustables.

3.3.2. Redes neuronales artificiales

Una red neuronal artificial está formada por neuronas conectadas mediante pesos. Generalmente incluye una capa de entrada, una o más capas ocultas y una capa de salida. Durante el entrenamiento, el modelo ajusta sus pesos para reducir errores y mejorar su desempeño.

3.3.3. Aprendizaje profundo

El aprendizaje profundo utiliza redes con múltiples capas para aprender representaciones complejas. Gracias a ello se aplica en visión por computadora, procesamiento de lenguaje natural, reconocimiento de voz y generación de contenido [4].

3.3.4. Ejemplo aplicado

Una red neuronal convolucional puede analizar imágenes médicas para detectar anomalías. Sus capas identifican desde características simples, como bordes y texturas, hasta patrones más complejos útiles para clasificar la imagen o señalar regiones relevantes.

3.3.5. Análisis

Su principal ventaja es la capacidad de aprender patrones complejos en imágenes, texto, audio y video. Sus principales limitaciones son el alto costo computacional, la necesidad de grandes cantidades de datos y la dificultad para interpretar sus decisiones.

3.4. Modelos de toma de decisiones

3.4.1. Definición

Los modelos de toma de decisiones permiten seleccionar una acción entre varias alternativas. Representan elementos como estados, acciones, metas, costos, recompensas o utilidad, con el objetivo de elegir la opción más adecuada para alcanzar un resultado.

3.4.2. Elementos principales

En los modelos de toma de decisiones suelen considerarse los siguientes elementos:

- **Estado actual:** describe la situación en la que se encuentra el sistema.
- **Acciones posibles:** opciones que el sistema puede ejecutar.
- **Modelo de transición:** indica cómo cambia el estado después de aplicar una acción.
- **Meta:** condición o resultado que se desea alcanzar.
- **Criterio de evaluación:** permite comparar alternativas mediante costo, utilidad o recompensa.

3.4.3. Modelos de búsqueda

La búsqueda es una forma de toma de decisiones que explora estados posibles para encontrar una solución. Métodos como búsqueda en amplitud, búsqueda en profundidad, costo uniforme y A* permiten comparar rutas o secuencias de acciones cuando el problema puede formularse como un espacio de estados [1].

3.4.4. Aprendizaje por refuerzo como modelo de decisión

El aprendizaje por refuerzo permite que un agente aprenda mediante interacción con el ambiente. El agente observa un estado, ejecuta una acción, recibe una recompensa o castigo y ajusta su comportamiento para maximizar la recompensa acumulada. Se aplica en videojuegos, robótica, navegación autónoma y optimización de recursos.

3.4.5. Ejemplo aplicado

Un sistema GPS es un ejemplo de toma de decisiones: parte de una ubicación inicial, considera rutas disponibles, evalúa costos como distancia, tiempo o tráfico, y selecciona el camino más conveniente hacia el destino.

3.4.6. Análisis

Su ventaja principal es que permiten planear, comparar alternativas y optimizar acciones. Se aplican en navegación, logística, videojuegos y robótica. Su limitación es que el número de estados puede crecer demasiado, aumentando el consumo de tiempo y memoria; además, en aprendizaje por refuerzo pueden requerirse muchas interacciones para aprender una estrategia efectiva.

4. Comparación entre los modelos de IA

Los modelos de Inteligencia Artificial pueden compararse según la forma en que representan información, el tipo de problema que resuelven, la cantidad de datos que requieren, su capacidad de explicación y su costo computacional. La siguiente tabla resume las características principales de los cuatro tipos de modelos analizados.

Modelo	Representación principal	Aplicación representativa	Limitación principal
Basado en reglas	Reglas, símbolos y relaciones lógicas.	Sistemas expertos, diagnóstico, soporte técnico.	Rigidez ante cambios o excepciones.
Probabilístico	Probabilidades, hipótesis y evidencia.	Filtros de spam, diagnóstico, predicción de riesgos.	Depende de probabilidades confiables.
Bioinspirado	Neuronas artificiales, pesos y capas.	Visión, voz, texto, reconocimiento de patrones.	Alto costo computacional y baja interpretabilidad.
Toma de decisiones	Estados, acciones, metas, costos y recompensas.	GPS, robótica, videojuegos, logística.	Puede enfrentar espacios de búsqueda enormes.

Tabla 1: Comparación general de modelos de Inteligencia Artificial.

Esta comparación muestra que no existe un modelo universalmente superior. La elección depende del problema, los datos disponibles, la necesidad de explicación, el costo computacional y el nivel de incertidumbre del ambiente.

5. Agentes inteligentes y su relación con los modelos

5.1. ¿Qué es un agente inteligente?

Un agente inteligente es una entidad que percibe su entorno y actúa sobre él para alcanzar objetivos. Su estructura básica incluye sensores, una función de agente y actuadores. Puede ser humano, robótico o de software, dependiendo del tipo de ambiente y acciones que realice.

5.2. Diferencia entre modelo y agente

Un modelo representa, predice o decide sobre una parte del problema. Un agente, en cambio, utiliza uno o varios modelos para percibir, razonar y actuar dentro de un ambiente. Por ejemplo, un termostato usa una regla como modelo de decisión, mientras que un GPS usa mapas, costos y búsqueda para seleccionar rutas.

5.3. Agentes de reflejo simple

Los agentes de reflejo simple toman decisiones mediante reglas condición–acción. Reaccionan a la percepción actual sin almacenar una historia compleja ni planear acciones futuras.

5.3.1. Ejemplo aplicado

Un termostato activa la calefacción o el aire acondicionado según la temperatura detectada. También una lámpara con sensor de movimiento se enciende cuando detecta presencia.

5.3.2. Análisis

Son rápidos, simples y de bajo costo computacional. Sin embargo, no aprenden, no planean y pueden fallar si el ambiente cambia o si la percepción es incompleta.

5.4. Agentes basados en metas

Los agentes basados en metas actúan para alcanzar un objetivo. Consideran acciones posibles y seleccionan una secuencia que los acerque al estado deseado.

5.4.1. Ejemplo aplicado

Un GPS parte de la ubicación actual, define un destino, evalúa rutas y selecciona un camino según distancia, tiempo o tráfico.

5.4.2. Análisis

Son útiles en navegación, planificación, robótica y logística. Su ventaja es que pueden planear antes de actuar; su limitación es el crecimiento del espacio de estados, que puede aumentar el costo computacional.

5.5. Agentes basados en utilidad y aprendizaje

Los agentes basados en utilidad eligen la alternativa más conveniente según una medida de preferencia. Los agentes con aprendizaje modifican su comportamiento a partir de la experiencia y pueden mejorar su desempeño con el tiempo.

6. Representación de problemas y búsqueda de soluciones

6.1. ¿Qué significa representar un problema en IA?

Representar un problema en IA consiste en traducir una situación real a una estructura formal que pueda ser procesada por un modelo o algoritmo. Una representación común es el espacio de estados, que contiene las configuraciones posibles y sus transiciones.

6.2. Elementos de la representación de problemas

Para formular un problema de búsqueda se consideran:

- **Estado inicial:** punto de partida.
- **Acciones posibles:** decisiones o movimientos disponibles.
- **Modelo de transición:** resultado de aplicar una acción.
- **Prueba de meta:** criterio para saber si se alcanzó el objetivo.
- **Costo del camino:** medida para comparar soluciones.
- **Restricciones:** condiciones que limitan las acciones.

6.3. Ejemplo aplicado: el mensajero perdido

En la dinámica del mensajero perdido, el objetivo es encontrar una ruta desde una oficina central hasta una casa. El estado inicial es la ubicación del mensajero; las acciones son los movimientos posibles; la meta es llegar al destino; y el costo puede medirse en distancia, tiempo o número de pasos.

6.4. Métodos de búsqueda

Entre los métodos más comunes se encuentran:

- **Búsqueda en amplitud:** explora primero los nodos más cercanos.
- **Búsqueda en profundidad:** avanza por una rama antes de retroceder.
- **Costo uniforme:** expande el camino con menor costo acumulado.
- **Búsqueda A*:** combina costo acumulado y heurística hacia la meta.

Estos métodos permiten resolver problemas de forma sistemática, aunque pueden volverse costosos cuando el espacio de estados es muy grande.

6.5. Relación entre problema, modelo y agente

Primero se analiza el problema: estados, acciones, restricciones, datos e incertidumbre. Después se elige un modelo adecuado. Si el sistema debe interactuar con un ambiente, se diseña un agente que utilice uno o varios modelos para actuar.

7. Aplicaciones integradoras de la Inteligencia Artificial

7.1. Visión por computadora

La visión por computadora permite interpretar imágenes, videos o información visual para tomar decisiones. Se aplica en clasificación, detección de objetos, segmentación y reconstrucción 3D [5].

7.1.1. Ejemplo aplicado

Un vehículo autónomo utiliza visión por computadora para detectar peatones, señales de tránsito, carriles y otros vehículos.

7.1.2. Análisis

Su ventaja es que automatiza tareas visuales complejas. Su limitación es la sensibilidad a iluminación, ruido, perspectiva, oclusiones y sesgos en los datos.

7.2. Procesamiento del Lenguaje Natural

El Procesamiento del Lenguaje Natural permite a las máquinas comprender, interpretar y generar lenguaje humano. Es complejo porque el lenguaje incluye contexto, intención, ambigüedad y variación cultural [6].

7.2.1. Ejemplo aplicado

Un asistente virtual identifica la intención del usuario, recupera información y genera una respuesta. También se aplica en traducción automática, resumen, análisis de sentimientos y chatbots.

7.2.2. Análisis

El PLN facilita la comunicación humano-computadora, pero puede fallar ante ironía, ambigüedad o contexto incompleto. Además, los modelos generativos pueden producir información incorrecta con apariencia convincente.

7.3. Robótica, autonomía y sistemas integrados

La robótica integra percepción, planificación, control, aprendizaje y toma de decisiones. Un robot inteligente debe actuar en ambientes físicos con obstáculos, incertidumbre y restricciones de seguridad.

Un robot de servicio, por ejemplo, puede combinar visión por computadora, búsqueda de rutas, sensores, reglas de seguridad y aprendizaje automático. Su ventaja es conectar la IA con el mundo físico; su limitación es que los errores pueden tener consecuencias materiales o humanas.

8. Discusión final: selección del enfoque adecuado

8.1. No existe un modelo universal

Cada modelo de IA tiene condiciones específicas de uso. Algunos requieren reglas claras, otros grandes volúmenes de datos, otros probabilidades confiables o buenas heurísticas. Por ello, elegir un modelo implica analizar el problema, los recursos, el ambiente, la incertidumbre y los criterios de evaluación.

8.2. Criterios para seleccionar un modelo o agente

Para elegir un enfoque conviene preguntarse:

- ¿El problema tiene reglas claras?
- ¿Existe incertidumbre?
- ¿Hay suficientes datos?
- ¿Se requiere explicación?
- ¿El sistema debe actuar en un ambiente?
- ¿Debe planear acciones?
- ¿Debe aprender con la experiencia?

8.3. Importancia de los sistemas híbridos

En la práctica, muchos sistemas combinan varios modelos. Un vehículo autónomo, por ejemplo, puede usar visión por computadora, modelos probabilísticos, búsqueda, reglas de seguridad y aprendizaje automático. Esto muestra que la IA moderna depende de la integración adecuada de modelos y agentes.

9. Conclusión

Los modelos de Inteligencia Artificial permiten representar y resolver problemas desde distintos enfoques. Los modelos basados en reglas destacan por su interpretabilidad; los probabilísticos permiten razonar bajo incertidumbre; los bioinspirados aprenden patrones complejos a partir de datos; y los modelos de toma de decisiones ayudan a seleccionar acciones según metas, costos o recompensas.

Los agentes inteligentes complementan estos modelos, ya que utilizan uno o varios de ellos para percibir, razonar y actuar dentro de un ambiente. Por ello, modelo y agente no son conceptos equivalentes: el modelo representa o procesa información, mientras que el agente la usa para tomar decisiones y ejecutar acciones.

La representación de problemas permite decidir qué modelo o agente conviene utilizar según los datos, la incertidumbre, las restricciones y los objetivos. En aplicaciones actuales, esta integración es evidente en sistemas como vehículos autónomos, asistentes virtuales y modelos generativos. En particular, los transformers han sido una aplicación tangible de los modelos bioinspirados y del aprendizaje profundo, y revolucionaron la IA generativa al permitir avances en traducción, resumen, generación de texto, código e interacción conversacional [11].

En conclusión, la IA es un campo integrador: combina modelos, agentes, representación, aprendizaje y toma de decisiones para construir sistemas capaces de resolver problemas reales. Su desarrollo debe considerar no solo el desempeño técnico, sino también la seguridad, la transparencia, la ética y el impacto social.

10. Bibliografía

Referencias

- [1] Russell, S. J., & Norvig, P. (2010). *Artificial Intelligence: A Modern Approach* (3.^a ed.). Pearson.
- [2] Poole, D., Mackworth, A., & Goebel, R. (1998). *Computational Intelligence: A Logical Approach*. Oxford University Press.
- [3] Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.
- [4] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [5] Szeliski, R. (2022). *Computer Vision: Algorithms and Applications* (2.^a ed.). Springer.
- [6] Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing*. Manuscrito en línea.
- [7] Material de clase. (2026). *Introducción a la Inteligencia Artificial*. Facultad de Ingeniería, UNAM.
- [8] Material de clase. (2026). *Agentes inteligentes y ambientes*. Facultad de Ingeniería, UNAM.
- [9] Material de clase. (2026). *Representación de problemas y búsqueda de soluciones*. Facultad de Ingeniería, UNAM.
- [10] Material de clase. (2026). *Aplicaciones de Inteligencia Artificial*. Facultad de Ingeniería, UNAM.
- [11] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*.